




SVM

SVM 전반적인 설명


svm : support Vector Machine

- 고차원 데이터의 분류문제에 좋은 성능
- 트레이드오프(generalization ability, training data) 관계에서 generalization ability 증가시키는 방향
- Statistical learning theory에 근거

SVM 상황



→ 이진분류문제



→ hyperplane을 찾자!


그런데 너무 많다...

svm 기준 | Margin

바로 **Margin!**

마진을 최대화할 수 있는 hyperplane을 찾자

→ generalization error를 최소화



Margin :

각 클래스에서 가장 가까운 관측치 사이의 거리

W로 표현 가능 ($Wx + b$)

1) Plus-plane

빨간색 클래스가 $y=1$


$$W^T X_i + b \geq 1$$

2) Minus-plane

파란색 클래스가 $y=-1$

$$W^T X_i + b \leq -1$$

이 2개 사이의 거리가 Margin이고 이 마진을 최대화하는 hyperplane을 찾자



최적의 decision boundary

$$W^T X_i + b = 0$$

그리고 이 둘의 관계는

$$x^+ = x^- + \lambda w$$

즉, 평행이동관계

수학적으로 보는 Margin

λ 구하기

$$w^T x^+ + b = 1$$

$$\Rightarrow w^T (x^- + \lambda w) + b = 1$$

$$\Rightarrow w^T x^- + b + \lambda w^T w = 1$$

$$\text{여기서 } w^T x^- + b = -1$$

$$\Rightarrow -1 + \lambda w^T w = 1$$

$$\lambda = \frac{2}{w^T w}$$

⚠ 잊지말자 우리는 w 에 주목! ⚠

Margin 구하기

Margin

$$\begin{aligned} &= \text{distance}(x^+, x^-) \\ &= \|x^+ - x^-\|_2 \\ &= \|x^- + \lambda w - x^-\|_2 \\ &= \|\lambda w\|_2 \\ &= \lambda \sqrt{w^T w} \\ &= \frac{2}{\sqrt{w^T w}} \\ &= \frac{2}{\|w\|_2} \end{aligned}$$

결론!

$$\max \text{margin} = \max \frac{2}{\|w\|_2} \Rightarrow \min \frac{\|w\|_2}{2}$$

$$\text{목적식} : \text{minimize} \frac{\|w\|_2^2}{2}$$

$$\text{제약식} : y_i(w^T x_i + b) \geq 1, i = 1, 2, 3, \dots, n$$

Lagrangian multiplier를 이용하여 Lagrangian Primal

$$\max_a \min_{w,b} L(w, b, \alpha) = \frac{1}{2} \|w\|_2^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$$

우선 **min**문제 해결 \rightarrow 미분 = 0

$$\bullet \text{ } w \text{에 대한 미분} \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\bullet \text{ } b \text{에 대한 미분} \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{1}{2} \|w\|_2^2 = \frac{1}{2} \sum_{i=1}^n \alpha_i y_i (\sum_{i=1}^n \alpha_i y_i x_i^T x_i) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$\begin{aligned} \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1) &= \sum_{i=1}^n \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^n \alpha_i = \\ &= \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j + \sum_{i=1}^n \alpha_i \end{aligned}$$

* 이제 α 만 구하면 w, b 알 수 있다

이제 **max**문제를 해결한다. | Lagrangian dual solution

$$\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

이 문제를 풀기 위해서는 KKT conditions를 만족해야 한다.

① Stationarity

$$\frac{\partial \mathcal{L}(w, b, \alpha)}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i \quad \frac{\partial \mathcal{L}(w, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

② Primal feasibility $y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, n$

③ Dual feasibility $\alpha_i \geq 0, i = 1, 2, \dots, n$

④ Complementary slackness $\alpha_i(y_i(w^T x_i + b) - 1) = 0$

4번을 이용해서 구해본다.

1) $\alpha_i > 0$ 일 때, 뒤에가 0

\Rightarrow +/- plane위에 위치, 이를 support vector 라고 부른다.

2) $\alpha_i = 0$ 일 때, 뒤에가 0일 필요 없다.

w, b 구하기

목표였던 w 를 구하자면

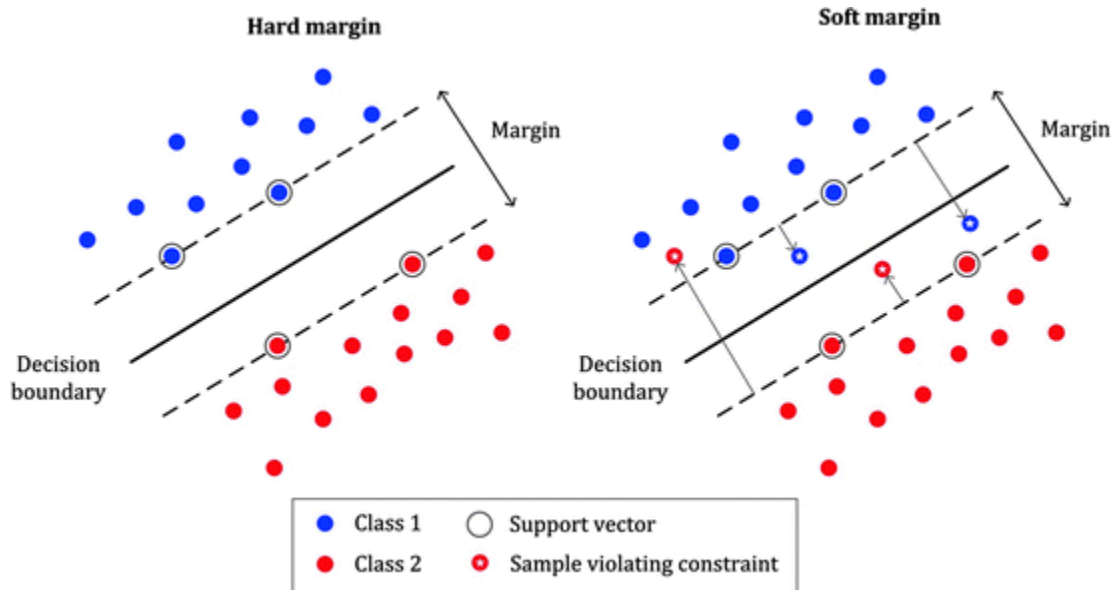
support vector일 때만 $\alpha_i^* \geq 0$ 이니까

support vector만 가지고 decision boundary 구할 수 있다.

$$w = \sum_{i=1}^n \alpha_i y_i x_i$$

b는 support vector 값 하나 (x_{sv}, y_{sv}) 를 넣어봐서 구할 수 있다.

지금까지 살펴본 **linear**한 SVM을 **HardMargin**이라고 한다.



Non-linear SVM

soft margin이란

직선으로는 분류하기 힘들다

→ 약간의 error를 허용하자!

$$\text{목적식} : \text{minimize} \frac{\|w\|_2^2}{2} + C \sum_{i=1}^n \xi_i$$

(ξ : 허용하는 error)

Hard margin과 비교해보면 뒤에 정규화 식이 붙었다.

trade-off | C

허용하는 error vs margin

C : trade-off를 결정하는 parameter

C가 높을 수록, error 많이 허용하지 않는다. (하드마진에 가까워진다.)

C가 작을 수록 error 많이 허용한다. (소프트마진에 가까워진다.)

Kernel

SVM에서 선형으로 분리할 수 없는 점들을 분류하기 위해 사용한다.

$$f(x) = \sum_{i \in SV} \alpha_i^* y_i K + b$$

- Linear Kernel
 - $K(x_1, x_2) = \langle x_1, x_2 \rangle$
- Polynomial Kernel
 - $K(x_1, x_2) = (\langle x_1, x_2 \rangle + b)^d$
- Sigmoid Kernel
 - $K(x_1, x_2) = \tanh(a \langle x_1, x_2 \rangle + b)$
- Gaussian Kernel (rbf kernel)
 - $K(x_1, x_2) = \exp\left(-\frac{\|x_1 - x_2\|_2^2}{2\sigma^2}\right)$